

Clusterização Adaptativa de Acervos Visuais: Uma Abordagem Baseada em Aprendizado Não Supervisionado e Otimização Combinatória de Borda

Vinícius Cavalcante Martins¹, José Carvalho Neto¹

¹Departamento de Ciências da Computação (DCC)
Universidade Federal de Roraima (UFRR)

viniciusmartinsroyal@gmail.com, Josecarvalhoneto3@gmail.com

Abstract. *This paper presents the design, formalization and implementation of an adaptive clustering engine for automated organization of image collections, developed as the final project for the DCC606 course (Algorithm Analysis) at UFRR. The system extracts visual feature vectors via Color Histograms (RGB) and Histogram of Oriented Gradients (HOG), and applies two manually implemented clustering algorithms: K-Means++ and Partitioning Around Medoids (PAM). A topological penalty term inspired by Markov Random Fields (Eq. 14) is incorporated into the objective function. Experiments on the Corel-1k dataset (1000 images, 208-dimensional feature vectors) show that K-Means++ converges in under 50 ms with WCSS of 346.5, while PAM achieves comparable Silhouette scores (0.044) at a significantly higher computational cost (140 s). The system is validated through a practical application that automatically organizes images into indexed directories corresponding to the generated clusters.*

Resumo. *Este artigo apresenta o projeto, a formalização matemática e a implementação de um motor de clusterização adaptativa para organização automatizada de acervos de imagens, desenvolvido como projeto final da disciplina DCC606 (Análise de Algoritmos) da UFRR. O sistema extrai vetores de características visuais via Histograma de Cores (RGB) e Histograma de Gradientes Orientados (HOG), e aplica dois algoritmos de clusterização implementados manualmente: K-Means++ e Particionamento em Torno de Medoides (PAM). Um termo de penalidade topológica inspirado em Campos Aleatórios de Markov (Eq. 14) é incorporado à função objetivo. Experimentos no dataset Corel-1k (1000 imagens, vetores de 208 dimensões) mostram que o K-Means++ converge em menos de 50 ms com WCSS de 346,5, enquanto o PAM alcança Silhouette comparável ($\approx 0,044$) a custo computacional expressivamente maior (≈ 140 s). O sistema é validado por uma aplicação prática que organiza automaticamente imagens em diretórios indexados correspondentes aos clusters gerados.*

1. Introdução

Na era da transformação digital, organizações dos mais variados setores — empresas de mídia, instituições públicas, operadoras de logística e universidades — produzem diariamente volumes massivos de dados visuais não estruturados. A catalogação e indexação manual desses acervos é operacionalmente inviável e financeiramente dispendiosa.

Abordagens baseadas em aprendizado profundo supervisionado, embora de alta acurácia, dependem de grandes bases rotuladas e demandam infraestrutura computacional de alto custo energético, contrariando as diretrizes de *Green AI* e governança ESG.

Surge, assim, uma demanda crítica por sistemas eficientes de aprendizado não supervisionado voltados para *Edge Computing*: soluções capazes de categorizar fluxos de imagens em tempo real com base em similaridade estrutural e cromática, sem depender de rotulagem prévia ou modelos de grande porte.

Sob a ótica da Pesquisa Operacional, o agrupamento (*clustering*) de dados em alta dimensão constitui um problema de particionamento NP-difícil [Garey and Johnson 1979]. A busca pela partição ótima de vetores de características visuais exige métodos heurísticos avançados, estratégias gulosas de inicialização e técnicas de busca local para mitigar a convergência a ótimos locais subótimos.

Este trabalho tem como objetivo projetar, formalizar matematicamente e implementar em C++17 um motor de clusterização adaptativa para categorização automatizada de acervos de imagens. O sistema processa imagens brutas, extrai descritores clássicos de visão computacional e aplica dois algoritmos de particionamento implementados manualmente: K-Means++ e PAM (*Partitioning Around Medoids*). A fundamentação teórica é ancorada na análise crítica do artigo de Chen, Luo e Parker [Chen et al. 1998], que propõe uma extensão adaptativa do K-Means para segmentação de imagens tridimensionais, combinando restrições espaciais via Campos Aleatórios de Markov com operações morfológicas orientadas por conhecimento. O algoritmo proposto por Chen et al. estende diretamente o trabalho seminal de Pappas [Pappas and Jayant 1989] sobre clusterização adaptativa com restrições de vizinhança.

O código-fonte completo está disponível em: https://github.com/vinimartinsufr/FP_DCC606_Tema_8_RR_2026

2. Fundamentação Teórica: Análise do Artigo de Chen, Luo e Parker (1998)

A fundamentação central deste projeto é o artigo de Chen, Luo e Parker [Chen et al. 1998], que propõe um algoritmo robusto de segmentação de imagens tridimensionais combinando clusterização adaptativa K-Means com operações morfológicas orientadas por conhecimento anatômico. O trabalho estende diretamente o algoritmo de Pappas [Pappas and Jayant 1989] — que introduziu restrições espaciais via MRF no K-Means clássico — incorporando estimação iterativa de variâncias locais e modelagem 3D de vizinhança. A análise a seguir dissecar os três pilares teóricos relevantes para este projeto.

2.1. Extensão do K-Means via Potencial de Gibbs e Campos Aleatórios de Markov

O K-Means clássico trata cada pixel de forma independente, ignorando qualquer estrutura de vizinhança. Chen et al. incorporam restrições espaciais por meio da teoria dos Campos Aleatórios de Markov (MRF — *Markov Random Fields*), seguindo a formulação introduzida por Pappas [Pappas and Jayant 1989] e estendendo-a para o caso volumétrico 3D.

Em um MRF, a probabilidade de um rótulo atribuído a um pixel x_s é condicionada aos rótulos de seus vizinhos N_s :

$$p(x_s|x_t, \forall t \neq s) = p(x_s|x_t, t \in N_s) \quad (1)$$

A cada par de pixels vizinhos está associado um potencial de clique de Gibbs, definido por Chen et al. como:

$$V_C(x) = \begin{cases} \beta, & \text{se } x_s \neq x_t \text{ e } s, t \in C \\ -\beta, & \text{se } x_s = x_t \text{ e } s, t \in C \end{cases} \quad (2)$$

onde $\beta > 0$ controla a força da restrição espacial. Quando dois pixels vizinhos pertencem ao mesmo cluster, a energia do sistema diminui; quando pertencem a clusters distintos, ela aumenta. A distribuição conjunta dos rótulos segue então uma distribuição de Gibbs:

$$p(x) \propto \exp \left\{ - \sum_C V_C(x) \right\} \quad (3)$$

Esta formulação torna o problema de segmentação equivalente a um problema de minimização de energia, favorecendo regiões contínuas e homogêneas e reduzindo fragmentação causada por ruído. Para imagens 3D, Chen et al. estendem o sistema de vizinhança de quatro vizinhos 2D para seis vizinhos volumétricos, aumentando o número de cliques de dois pontos e, conseqüentemente, a força da regularização espacial.

2.2. Modelagem Estatística Local e Janelas Adaptativas

Um dos avanços centrais de Chen et al. em relação ao trabalho original de Pappas é a estimação iterativa não apenas das médias locais, mas também das *variâncias* locais de cada cluster. Imagens médicas — e, por extensão, acervos fotográficos com variações de iluminação — frequentemente violam a hipótese de intensidade constante por cluster assumida pelo K-Means global.

Os autores modelam a densidade condicional da imagem y dada a segmentação x como um processo gaussiano espacialmente variável:

$$p(y|x) \propto \exp \left\{ - \sum_s \frac{1}{2\sigma_s^2} (y_s - \mu_s)^2 \right\} \quad (4)$$

onde μ_s e σ_s^2 são a média e a variância locais do cluster ao qual o pixel s pertence, atualizadas iterativamente durante o processo de segmentação. Combinando esse termo de fidelidade aos dados com as restrições espaciais do MRF, a função de probabilidade conjunta que o algoritmo maximiza é:

$$p(x|y) \propto \exp \left\{ - \sum_s \frac{1}{2\sigma_s^2} (y_s - \mu_s)^2 - \sum_C V_C(x) \right\} \quad (5)$$

Na prática, essa abordagem funciona como um sistema de janelas adaptativas (*sliding windows*): os parâmetros estatísticos de cada cluster são estimados localmente, permitindo que o algoritmo acompanhe gradientes de iluminação e variações de contraste

sem perder a coerência global da segmentação. A otimização é realizada pelo método de *Iterative Conditional Modes* (ICM), que maximiza a probabilidade *a posteriori* pixel a pixel até que nenhum pixel mude de classe.

2.3. Operações Morfológicas e Heurísticas de Correção

O terceiro pilar do artigo é o uso de operações morfológicas orientadas por conhecimento para corrigir ambiguidades que a clusterização adaptativa, por ser baseada em intensidade, não consegue resolver sozinha. Chen et al. aplicam abertura e fechamento morfológico clássicos — definidos sobre erosão $E(\mathbf{A}, \mathbf{B}) = \mathbf{A} \ominus \mathbf{B}$ e dilatação $D(\mathbf{A}, \mathbf{B}) = \mathbf{A} \oplus \mathbf{B}$ — para eliminar regiões isoladas e preencher cavidades internas.

O diferencial do artigo está nas *curvas de ação*: o sistema monitora área, perímetro e razão de forma de cada fatia e calcula:

$$ACTION_k = \frac{\Delta_k \text{area}}{T_1} + \frac{\Delta_k \text{peri}}{T_2} + \frac{\Delta_k \text{ratio}}{T_3} \quad (6)$$

Quando $ACTION_k$ ultrapassa limiares predefinidos, operações morfológicas baseadas em conhecimento anatômico são ativadas automaticamente. Para lidar com casos em que o ajuste necessário é menor do que uma operação morfológica padrão produziria, os autores introduzem erosão e dilatação *estocásticas*: pixels de borda são removidos ou adicionados com probabilidade controlada, produzindo operações de raio subpixel que permitem ajustes finos da segmentação.

Esta combinação de otimização combinatória, modelagem probabilística e correção heurística orientada por conhecimento do domínio é diretamente análoga à estratégia adotada neste projeto: o termo de penalidade topológica λ da Eq. 8 cumpre papel semelhante ao potencial de Gibbs de Chen et al., penalizando partições fragmentadas e impondo continuidade contextual entre imagens vizinhas no acervo.

3. Formulação Matemática do Problema

Seja $\mathcal{I} = \{i_1, i_2, \dots, i_n\}$ o conjunto de imagens de entrada e $\mathcal{X} = \{x_1, x_2, \dots, x_n\}$ o conjunto de vetores de características correspondentes, onde cada $x_k \in \mathbb{R}^d$ representa um vetor de alta dimensão. O problema de agrupamento particional busca dividir os n vetores em exatamente K clusters disjuntos $\mathcal{S} = \{S_1, S_2, \dots, S_K\}$, cada um com centroide $\mu_j \in \mathbb{R}^d$.

A formulação padrão minimiza o WCSS (*Within-Cluster Sum of Squares*):

$$\min_{\mathcal{S}} f(\mathcal{S}) = \sum_{j=1}^K \sum_{x_k \in S_j} \|x_k - \mu_j\|^2 \quad (7)$$

Para este projeto, adiciona-se uma componente de penalidade de regularização topológica inspirada na formulação MRF de Chen et al. [Chen et al. 1998]:

$$\min_{\mathcal{S}} \Phi(\mathcal{S}) = \sum_{j=1}^K \sum_{x_k \in S_j} \|x_k - \mu_j\|^2 + \lambda \sum_{(k,r) \in E} \delta(\mathcal{S}(x_k), \mathcal{S}(x_r)) \quad (8)$$

onde E define um grafo de adjacência linear entre imagens consecutivas na ordem do dataset, $\lambda \in \mathbb{R}^+$ é o multiplicador de regularização, e δ é a função delta de Kronecker: $\delta(a, b) = 0$ se $a = b$, e 1 caso contrário. O segundo termo penaliza partições fragmentadas de dados correlacionados, modelando continuidade temporal ou de contexto entre imagens vizinhas — analogamente ao potencial de Gibbs entre pixels vizinhos proposto por Chen et al. [Chen et al. 1998].

O problema de clusterização ótima é NP-difícil [Garey and Johnson 1979]: o número de partições possíveis de n elementos em K grupos cresce como $O(K^n/K!)$, tornando a busca exaustiva computacionalmente inviável para n e K não triviais. Neste trabalho, são empregadas duas heurísticas de aproximação descritas na Seção 5.

4. Descrição do Cenário de Aplicação

O cenário de aplicação prática é a organização automatizada de acervos fotográficos institucionais. Em contextos como os da UFRR — coberturas de eventos de extensão, campanhas institucionais, inspeções de campo e registros acadêmicos — dezenas de milhares de imagens são produzidas anualmente sem qualquer catalogação estruturada.

O sistema proposto ingere uma coleção de fotografias em formato bruto (JPEG/PNG), extrai vetores de características visuais e agrupa as imagens em K clusters por similaridade cromática e estrutural. Ao final, as imagens são automaticamente copiadas para diretórios indexados (`Cluster_0`, `Cluster_1`, ..., `Cluster_k-1`), fornecendo uma organização inicial que reduz drasticamente o esforço manual de catalogação.

A solução é projetada para operar em ambientes de *Edge Computing* — servidores locais ou estações de trabalho sem GPU — consumindo recursos computacionais modestos e sem dependência de conectividade de rede ou serviços em nuvem.

5. Implementação

O sistema foi implementado em C++17 com OpenCV 4, organizado em módulos estanques. A restrição de escopo do enunciado — que proíbe o uso de classes prontas de clusterização — foi integralmente atendida: toda a lógica de distâncias, atualização de centroides e busca local foi desenvolvida de forma nativa.

5.1. Módulo 1 — Extração de Características

Para cada imagem, o pipeline de extração opera em três etapas: leitura via OpenCV (`cv::imread`), redimensionamento para 64×64 pixels (padronização de custo e comparabilidade), e extração de dois descritores concatenados.

Histograma de Cores RGB: A imagem é quantizada em $b = 4$ bins por canal, produzindo um histograma tridimensional com $4^3 = 64$ dimensões, normalizado pelo total de pixels (distribuição de frequência). A escolha de $b = 4$ representa um compromisso entre discriminabilidade e custo computacional: valores maiores (e.g., $b = 8$, resultando em 512 dimensões) intensificam a maldição da dimensionalidade [Bellman 1957] para $n = 1000$ pontos.

HOG Simplificado: Implementação inspirada em Dalal e Triggs [Dalal and Triggs 2005], com grade espacial fixa de 4×4 células e $b_{hog} = 9$ bins

angulares em $[0, 180)$, resultando em $4 \times 4 \times 9 = 144$ dimensões. O gradiente é calculado por diferença central e o descritor é normalizado globalmente por norma L2. Esta implementação omite blocos sobrepostos e interpolação bilinear presentes no HOG completo de Dalal-Triggs, sendo portanto uma versão simplificada adequada ao objetivo de clusterização.

O vetor de características final possui $64 + 144 = 208$ dimensões por imagem. É importante observar que os dois descritores operam em escalas distintas (histograma com soma $\approx 1,0$; HOG com norma L2 $\approx 1,0$), o que pode introduzir assimetria na distância euclidiana. Esta é uma limitação conhecida do pipeline, declarada como trabalho futuro (normalização por z-score entre descritores).

5.2. Módulo 2 — Motor de Otimização Combinatória

K-Means++: Implementação do algoritmo de médias com inicialização probabilística gulosa. O primeiro centróide é escolhido aleatoriamente; os subsequentes são selecionados com probabilidade proporcional à distância quadrática ao centróide mais próximo já escolhido, espalhando a semente inicial e reduzindo o risco de convergência a ótimos locais ruins [Arthur and Vassilvitskii 2007]. A convergência é verificada pela movimentação dos centróides (tolerância $\epsilon = 10^{-4}$), com limite de 300 iterações.

A penalidade topológica (Eq. 8) é incorporada na etapa de atribuição: para cada ponto x_i , a energia é calculada como $\text{dist}^2(x_i, \mu_c) + \lambda \cdot \delta(\text{cluster}_{i-1}, c)$. Com $\lambda = 0$ (modo nativo), o algoritmo reduz-se ao K-Means++ padrão.

PAM (*Partitioning Around Medoids*): Implementação de busca local por trocas. Os medóides iniciais são selecionados pela mesma heurística do K-Means++ (probabilidade proporcional a dist^2). A cada passo, o algoritmo avalia todas as trocas possíveis entre um medóide e um não-medóide, aplicando a que produzir maior redução de custo. O processo repete até estabilização ou até atingir o limite de 50 passos.

O custo interno do PAM utiliza distância L2 bruta (não ao quadrado), que é a formulação canônica de k-medóides. O WCSS reportado na Tabela 1 é calculado a posteriori sobre os clusters resultantes, usando dist^2 , para permitir comparação uniforme com o K-Means++. O PAM é mais robusto a outliers que o K-Means, pois os centros são pontos reais do dataset.

5.3. Módulo de Visualização e Organização

Dois scripts Python em `tools/` realizam o pós-processamento: `visualizer.py` aplica PCA bidimensional (via scikit-learn, permitido pelo enunciado para visualização) e gera o gráfico de dispersão colorido por cluster; `organizer.py` lê o CSV de resultados gerado pelo C++ e copia cada imagem para o diretório `Cluster_k` correspondente.

6. Análise de Complexidade

6.1. Extração de Características

A extração do histograma de cores percorre todos os pixels da imagem redimensionada ($64 \times 64 = 4096$ pixels), resultando em $O(P)$ onde $P = 4096$. O HOG também opera em $O(P)$ (percorre a mesma grade de pixels). Para um dataset de n imagens, a complexidade total da extração é $O(n \cdot P)$, independente de K .

6.2. K-Means++

A inicialização K-Means++ requer K iterações, cada uma percorrendo os n pontos para atualizar distâncias mínimas: $O(K \cdot n \cdot d)$, onde $d = 208$ é a dimensionalidade.

Cada iteração do K-Means consiste em:

- **Atribuição:** $O(n \cdot K \cdot d)$ — cada ponto é comparado com todos os K centroides.
- **Atualização:** $O(n \cdot d)$ — recalcula centroides como média dos pontos atribuídos.

Para t iterações até convergência, a complexidade total é $O(t \cdot n \cdot K \cdot d)$. Na prática, $t \ll n$; nos experimentos realizados, t variou entre 14 e 33.

6.3. PAM

A inicialização do PAM segue a mesma heurística do K-Means++: $O(K \cdot n \cdot d)$.

A busca local é significativamente mais custosa. Cada passo avalia todas as combinações medoide $\times$ não-medoide:

- **Número de trocas avaliadas por passo:** $K \cdot (n - K)$
- **Custo de cada avaliação** (recalcular a energia da configuração): $O(n \cdot K \cdot d)$
- **Complexidade por passo:** $O(K \cdot (n - K) \cdot n \cdot K \cdot d) \approx O(n^2 \cdot K^2 \cdot d)$

Para p passos até estabilização, a complexidade total é $O(p \cdot n^2 \cdot K^2 \cdot d)$. Com $n = 1000$, $K = 10$, $d = 208$ e $p = 50$, isso representa da ordem de 10^{12} operações elementares, o que explica o tempo observado de ≈ 140 segundos mesmo com otimização de compilador (-O3).

6.4. Cálculo do Silhouette

O índice de Silhouette requer, para cada ponto, o cálculo da distância média a todos os pontos do mesmo cluster e a todos os pontos do cluster mais próximo: $O(n^2 \cdot d)$. Para $n = 1000$ e $d = 208$, isso corresponde a $\approx 2 \times 10^8$ operações, justificando seu cálculo separado do timer da Tabela 1.

7. Resultados Experimentais

Os experimentos foram realizados em ambiente Linux (Ubuntu) com compilador g++ -O3 -std=c++17 e OpenCV 4. O dataset de controle acadêmico utilizado foi o Corel-1k, composto por 1000 imagens distribuídas em 10 categorias semânticas, o que justifica a escolha de $K = 10$. O acervo real utilizado para validação prática é composto por 300 fotografias do projeto STELAS (CNPq), coletadas em três instituições de ensino superior: UFRR, UERR e IFB, com 100 imagens por instituição, registrando aulas e confraternizações do projeto. Para esse dataset, adotou-se $K = 3$, correspondendo diretamente às três origens institucionais.

A Tabela 1 apresenta os resultados do protocolo experimental (Tabela 7 do enunciado).

Tabela 1. Protocolo de Coleta de Métricas Experimentais

Dataset	N	Algoritmo	WCSS	Silhouette	Tempo
Corel-1k	1000	K-Means++ (Nativo)	345,95	0,0507	25,7 ms
Corel-1k	1000	PAM / Busca Local	489,46	0,0437	175.670 ms
Acervo Real (STELAS)	300	K-Means++ (Nativo)	90,45	0,0676	1,98 ms

7.1. Visualização PCA 2D

A Figura 1 apresenta a projeção bidimensional via PCA do espaço de características de 208 dimensões, gerada pelo `visualizer.py` a partir dos resultados do K-Means++ aplicado ao Corel-1k.




Figura 1. Projeção PCA 2D dos vetores de características (208 dimensões → 2D), coloridos por cluster. Resultado do K-Means++ com $K = 10$ sobre o dataset Corel-1k (1000 imagens).

A sobreposição pronunciada entre clusters no plano PCA é esperada e decorre de dois fatores: (i) a compressão de 208 dimensões para 2 inevitavelmente descarta variância relevante para a separação dos grupos; e (ii) os descritores de baixo nível utilizados (histograma de cores e HOG simplificado) capturam propriedades perceptuais, não semânticas. O agrupamento à direita da figura (clusters 3, 4, 6 e 7, aproximadamente $PCA1 > 0,5$) indica uma região do espaço de características bem separada do núcleo central, correspondente a imagens com assinatura cromática distintiva.

7.2. Análise Qualitativa dos Clusters

A distribuição de imagens por cluster resultou em: 132, 213, 99, 39, 31, 138, 84, 32, 118 e 114 imagens para os clusters 0 a 9, respectivamente. O desequilíbrio — com clusters variando de 31 a 213 imagens — é característico de algoritmos de particionamento por distância euclidiana aplicados a dados sem separabilidade linear clara.

A inspeção qualitativa dos clusters revelou que a organização gerada não preserva as 10 categorias semânticas originais do Corel-1k (e.g., 100 imagens de praia, 100 de ele-

fantes). Em vez disso, os grupos foram formados por similaridade cromática e estrutural de baixo nível:

- **Cluster 8** (118 imagens): concentrou imagens com dominância de tons de azul, incluindo fotografias de céu, piscinas, praias e mar — categorias semanticamente distintas, mas perceptualmente coerentes pela cor.
- **Cluster 9** (114 imagens): agrupou imagens de baixa luminosidade geral, como flores em sombra, aldeias escuras e monumentos com iluminação lateral pesada — coerência pela distribuição de intensidade, não por tema.
- **Cluster 5** (138 imagens): apresentou a maior heterogeneidade semântica, reunindo montanhas nevadas, retratos e elefantes, o que sugere que esses exemplos compartilham uma distribuição cromática intermediária sem dominância de canal específico, insuficientemente discriminada pelo HOG simplificado.

Este comportamento evidencia a limitação fundamental de descritores de baixo nível para tarefas de organização semântica: o sistema agrupa corretamente por *aparência visual*, mas não por *conteúdo*. Esta é precisamente a lacuna que motivou o desenvolvimento de algoritmos como o de Chen et al. [Chen et al. 1998] — e que, no estado da arte atual, é endereçada por descritores aprendidos via redes convolucionais, fora do escopo deste projeto.

7.3. Discussão Quantitativa dos Resultados

O K-Means++ apresentou WCSS consideravelmente menor que o PAM (345,95 contra 489,46). Esta diferença não implica que o K-Means++ produza partições de melhor qualidade: o PAM minimiza a distância L2 bruta ao medoide, enquanto o WCSS mensura distância ao quadrado. Os índices de Silhouette, agnósticos à métrica interna de cada algoritmo, resultaram comparáveis (0,0507 e 0,0437), confirmando que ambos produziram estruturas de agrupamento de qualidade similar.

Os valores de Silhouette próximos a zero refletem diretamente a sobreposição observada na Figura 1: clusters com fronteiras difusas no espaço de características produzem valores de $s(i) \approx 0$, indicando pontos que poderiam pertencer a clusters vizinhos com custo semelhante. Este é o comportamento esperado para descritores de 208 dimensões sobre um dataset com categorias semanticamente diversas.

A variabilidade entre execuções do K-Means++ (WCSS variando de 345,88 a 345,95 entre rodadas) é inerente à inicialização probabilística e confirma o caráter heurístico do algoritmo — cada execução converge a um mínimo local distinto.

A diferença de custo temporal entre os dois algoritmos é de aproximadamente quatro ordens de grandeza (25,7 ms contra 175.670 ms). Este resultado ilustra empiricamente o trade-off fundamental entre qualidade de solução e custo computacional: o PAM, com busca local exaustiva de trocas ($O(p \cdot n^2 \cdot K^2 \cdot d)$), paga um preço proibitivo para datasets de tamanho moderado, tornando o K-Means++ a escolha natural para o cenário de *Edge Computing* proposto.

7.4. Aplicação Prática: Acervo Real STELAS

A validação prática foi conduzida sobre o acervo fotográfico do projeto STELAS (CNPq), iniciativa nacional de inclusão de mulheres na computação, presente em diversas instituições de ensino superior brasileiras. O conjunto utilizado compreende 300 fotografias distribuídas igualmente entre três instituições — UFRR, UERR e IFB (100 imagens cada) —,

registrando aulas e confraternizações do projeto. As imagens foram coletadas em condições heterogêneas: variações de ângulo de captura (posição ereta ou deitada), iluminação ambiente distinta por instituição e composição visual diversa entre os ambientes.

A Figura 2 apresenta a projeção PCA 2D do espaço de características resultante.




Figura 2. Projeção PCA 2D dos vetores de características (208 dimensões $\rightarrow$ 2D), coloridos por cluster. Resultado do K-Means++ com $K = 3$ sobre o Acervo Real STELAS (300 imagens).

O algoritmo gerou três clusters com distribuição de 90, 112 e 98 imagens, respectivamente. A inspeção qualitativa dos diretórios organizados revelou padrões visuais coerentes com a hipótese de separação por instituição:

- **Cluster 0** (90 imagens): predominância de fotografias da UERR (58 imagens). A inspeção visual sugere que esse grupo concentra imagens em que as alunas aparecem com o corpo quase inteiro em evidência, o que pode ter influenciado tanto o descritor HOG — sensível à orientação e extensão de contornos humanos — quanto o histograma de cores, pela maior área de pele e vestimenta capturada no enquadramento.
- **Cluster 1** (112 imagens): predominância da UFRR (44 imagens). A caracterização visual é menos homogênea: predominam tons de branco e cinza, típicos de ambientes com paredes claras e iluminação artificial, mas com presença de *outliers* coloridos — imagens com dominância de azul e verde — que elevam a variância interna do cluster. Esse comportamento é consistente com o Silhouette

global do acervo ($\approx 0,068$): pontos na fronteira entre clusters apresentam custo de atribuição semelhante a grupos vizinhos.

- **Cluster 2** (98 imagens): predominância do IFB (44 imagens). A inspeção qualitativa indica que nesse grupo as fotografias frequentemente apresentam notebooks das alunas ocupando grande parte do enquadramento. Esse elemento visual recorrente pode ter contribuído para a coesão do cluster tanto pela assinatura cromática característica das telas (tonalidades frias e uniformes) quanto pela estrutura geométrica retilínea capturada pelo HOG.

A separação obtida, embora não perfeita, é qualitativamente interpretável: o algoritmo agrupou as imagens por características visuais de baixo nível que refletem, indiretamente, diferenças no ambiente físico e nas condições de registro de cada instituição. O Silhouette do acervo real (0,0676) supera ligeiramente o do Corel-1k (0,0507), o que é notável considerando que $K = 3$ impõe fronteiras mais amplas: clusters maiores tendem a apresentar maior coesão interna relativa quando os dados possuem alguma estrutura subjacente — neste caso, a identidade visual de cada ambiente institucional.

A validação externa pelo *ground truth* de origem (UFRR, UERR, IFB) confirma que a clusterização capturou parcialmente a estrutura real dos dados, demonstrando a viabilidade do sistema para organização automatizada de acervos fotográficos institucionais sem qualquer supervisão ou rotulagem prévia.

8. Declaração de uso de IA

"Agradecimentos: Os autores expressam seu agradecimento à ferramenta [Claude sonnet 4.6] da [Mantenedora, OpenAI / Anthropic] pelo suporte na revisão linguística e aprimoramento estilístico deste manuscrito. Todo o conteúdo conceitual, interpretação de dados e redação final foram rigorosamente supervisionados e validados pelos autores humanos, que assumem total responsabilidade pelo texto."

"Materiais e Métodos [De clusterização e plotação]: O desenvolvimento e a otimização dos scripts de [simulação/ treinamento do modelo / análise estatística / desenvolvimento] foram realizados com o suporte assistido do modelo de linguagem de grande porte [Claude sonnet 4.6]. A ferramenta foi empregada especificamente para a [especificar: refatoração de funções / automação de pipelines de dados]. Ressalta-se que toda a lógica algorítmica, parametrização e validação lógica do código gerado foram executadas e auditadas manualmente pelos autores."

"As figura usadas como Representação da arquitetura do sistema e graficos. Elas tiveram o conceitual inicial e os elementos de fluxo foram gerados/otimizados com o auxílio da ferramenta de IA [open ia chatgpt5 e Claude sonnet 4.6], sob estrito direcionamento técnico e conceitual dos autores."

9. Conclusão

Este trabalho apresentou o projeto, a formalização e a implementação de um motor de clusterização adaptativa para organização automatizada de acervos visuais. O sistema implementa manualmente os algoritmos K-Means++ e PAM, extrai vetores de características visuais clássicos (Histograma de Cores + HOG) e incorpora uma penalidade topológica inspirada na formulação MRF de Chen et al. [Chen et al. 1998], que por sua vez estende o

trabalho seminal de Pappas [Pappas and Jayant 1989] sobre clusterização adaptativa com restrições espaciais.

Os experimentos no Corel-1k demonstraram que o K-Means++ é altamente competitivo para o cenário de *Edge Computing*: converge em menos de 30 ms, produzindo qualidade de partição (Silhouette $\approx 0,051$) comparável ao PAM, que demanda aproximadamente 176 segundos para o mesmo dataset. O PAM permanece relevante para cenários onde robustez a *outliers* é prioritária e o tempo de processamento não é restrição crítica.

A validação prática sobre o acervo STELAS (300 imagens, três instituições) confirmou a aplicabilidade do sistema em cenários reais: o K-Means++ convergiu em menos de 2 ms com Silhouette de 0,068, produzindo agrupamentos qualitativamente interpretáveis pela assinatura visual de cada ambiente institucional. A correspondência parcial entre clusters gerados e origens reais — verificável pelo *ground truth* de procedência das imagens — valida a utilidade prática do motor proposto para organização automatizada de acervos fotográficos institucionais sem rotulagem prévia.

Como trabalhos futuros identificam-se: (i) normalização cross-feature por z-score antes da concatenação dos descritores, para equalizar as escalas do histograma de cores e do HOG; (ii) experimentação com t-SNE como alternativa ao PCA para visualização de alta dimensionalidade; (iii) avaliação com descritores mais ricos (SIFT, LBP) mantendo a restrição de não utilizar redes neurais; e (iv) implementação de critério de seleção automática de K via método do cotovelo ou índice de Davies-Bouldin.

Referências

- Arthur, D. and Vassilvitskii, S. (2007). k-means++: The advantages of careful seeding. In *Proceedings of the Eighteenth Annual ACM-SIAM Symposium on Discrete Algorithms (SODA)*, pages 1027–1035, New Orleans, Louisiana. Society for Industrial and Applied Mathematics.
- Bellman, R. (1957). *Dynamic Programming*. Princeton University Press, Princeton, NJ.
- Chen, C. W., Luo, J., and Parker, K. J. (1998). Image segmentation via adaptive K-mean clustering and knowledge-based morphological operations with biomedical applications. *IEEE Transactions on Image Processing*, 7(12):1673–1683.
- Dalal, N. and Triggs, B. (2005). Histograms of oriented gradients for human detection. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, volume 1, pages 886–893. IEEE.
- Garey, M. R. and Johnson, D. S. (1979). *Computers and Intractability: A Guide to the Theory of NP-Completeness*. W. H. Freeman and Company, New York.
- Pappas, T. N. and Jayant, N. S. (1989). An adaptive clustering algorithm for image segmentation. In *Proceedings of the IEEE International Conference on Acoustics, Speech, and Signal Processing (ICASSP)*, volume 3, pages 1667–1670, Glasgow, UK.